



Departament d'Estadística
i Investigació Operativa

UNIVERSITAT POLITÈCNICA DE CATALUNYA



ESTADÍSTICA

Repàs Blocs C i D

Desembre 2024

BLOC C

Objectiu Estadística



Estimació puntual

- **Estimació puntual:** valor que l'estimador $\hat{\theta}$ pren en una mostra concreta.

Per exemple $\bar{x} = \frac{\sum x_i}{n}$ és la mitjana mostral i és una estimació puntual de μ

- **Error tipus o error estàndard:** variabilitat de l'estimador. En el cas anterior de la MITJANA, l'error tipus (o estàndard) de la mitjana (o *mean standard error* o *se*) és:

$$se = \sqrt{V(\bar{X}_n)} = \sqrt{E[(\bar{X}_n - \mu)^2]} = \frac{\sigma}{\sqrt{n}}$$

Atenció: generalment, la σ serà desconeguda i l'error tipus l'haurem d'aproximar emprant l'estimador pertinent ($\hat{\sigma}$) amb les dades de la mostra: $\widehat{se} = \frac{\hat{\sigma}}{\sqrt{n}} = \frac{s}{\sqrt{n}}$ (amb s estimador puntual de σ)

Estimació puntual. Casos

Paràmetre (θ) (POBLACIÓ)	Estimador ($\hat{\theta}$) (MOSTRA)
μ (esperança, mitjana poblacional)	$\bar{x}$ (mitjana mostral)
σ^2 (variància poblacional) σ (desviació tipus poblacional)	s^2 (variància mostral) s (desviació tipus mostral)
π (probabilitat)	p (proporció)

El cas de la MITJANA:

$\bar{x} = \frac{\sum_{i=1}^n x_i}{n}$ mitjana mostral és una estimació puntual del paràmetre μ de tendència central

El cas de la DESVIACIÓ:

$s = \sqrt{\frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n-1}} = \sqrt{\frac{\sum_{i=1}^n x_i^2 - \frac{(\sum_{i=1}^n x_i)^2}{n}}{n-1}}$ desviació tipus mostral és una estimació puntual del paràmetre σ de dispersió

El cas de la PROPORCIÓ:


$p = \sum_{i, x_i=1} 1/n$ proporció mostral és una estimació puntual del paràmetre π

Intervals de confiança

Paràmetre	Premisses	Fórmula	Comentaris
μ	σ coneguda n "gran" o $X \sim N$	$\bar{x} \pm z_{1-\frac{\alpha}{2}} \cdot \frac{\sigma}{\sqrt{n}}$	Simètric. Han de donar σ a l'enunciat.
	σ desconeguda, $X \sim N$	$\bar{x} \pm t_{n-1, 1-\frac{\alpha}{2}} \cdot \frac{s}{\sqrt{n}}$	Simètric. T amb $(n-1)$ g.d.l.l
σ^2	$X \sim N$	$\left[\frac{s^2(n-1)}{\chi_{n-1, 1-\frac{\alpha}{2}}^2}, \frac{s^2(n-1)}{\chi_{n-1, \frac{\alpha}{2}}^2} \right]$	NO simètric. Quantils del denominador en ordre invers. És de σ^2 (no de σ)
π	$\pi \cdot n \geq 5$ i $(1-\pi) \cdot n \geq 5$	$P \pm z_{1-\frac{\alpha}{2}} \sqrt{\frac{\pi(1-\pi)}{n}}$	$\pi = P$ (habitual) o $\pi = 0.5$
$\mu_1 - \mu_2$	Aparellades, $D \sim N$, efecte additiu constant	$\bar{d} \pm t_{n-1, 1-\frac{\alpha}{2}} \cdot \frac{s_d}{\sqrt{n}}$	Simètric. Equivalent a μ d'una mostra. T amb $(n-1)$ g.d.l.l.
	Independents, $Y1 \sim N$ i $Y2 \sim N$, $\sigma_1^2 = \sigma_2^2$	$(\bar{y}_1 - \bar{y}_2) \pm t_{n_1+n_2-2, 1-\frac{\alpha}{2}} \cdot s \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}$	$s^2 = \frac{(n_1-1)s_1^2 + (n_2-1)s_2^2}{(n_1-1) + (n_2-1)}$ T amb $(n_1 + n_2 - 2)$ g.d.l.l
σ_1^2 / σ_2^2	Independents, $Y1 \sim N$ i $Y2 \sim N$	$\left[\frac{s_1^2 / s_2^2}{F_{(n_1-1, n_2-1), 1-\frac{\alpha}{2}}}, \frac{s_1^2 / s_2^2}{F_{(n_1-1, n_2-1), \frac{\alpha}{2}}} \right]$	NO simètric. Quantils del denominador en ordre invers. És de rati de σ^2 (no de σ)
$\pi_1 - \pi_2$	Independents, n's grans i p's no molt extremes	$\frac{(P_1 - P_2) \pm z_{1-\frac{\alpha}{2}} \cdot \sqrt{P_1(1-P_1)/n_1 + P_2(1-P_2)/n_2}}$	Simètric. n_1 i n_1 són de cada mostra.




Estimació per Interval de confiança. Confiança i risc

El càlcul d'un IC implica una confiança $1-\alpha$ (i per tant un risc α) que podem representar:



I podem relacionar el valor de confiança amb el quantil que necessitem per construir l'IC:
(com a exemple estan indicats els quantils per una Z Normal(0,1) on sabem que $z_{\alpha} = -z_{1-\alpha}$ o $z_{\alpha/2} = -z_{1-\alpha/2}$)

Confiança $1-\alpha$	Risc α	$\alpha/2$	$1 - \alpha/2$
0.95	0.05	0.025	0.975
0.90	0.10	0.05	0.95
0.99	0.01	0.005	0.995



Exemple. Embotelladora (assumint premissa de normalitat)

Una embotelladora d'ampolles de litre té una dispersió de $\sigma = 10\text{cc}$. En una mostra a l'atzar de $n = 100$ ampolles d'aquesta màquina, la mitjana observada ha sigut $\bar{x} = 995\text{cc}$.

Calculem un interval de confiança del 95% de μ .

$$IC(\mu, 0.95) = \bar{x} \pm z_{1-\frac{\alpha}{2}} \cdot \frac{\sigma}{\sqrt{n}} = 995 \pm 1.96 \cdot \frac{10}{\sqrt{100}} = 995 \pm 1.96 = [993.04, 996.96]$$

(l'amplada de l'interval és $1.96 \cdot 2 = 3.92$)

(amb una confiança del 95%, μ es troba entre 993.04 i 996.96, per sota dels 1000cc esperables)

* Si volguéssim una amplada de l'interval de 3.5 (meitat de l'interval = 1.75):

quina hauria de ser n sense canviar la confiança?

$$1.75 = 1.96 \cdot \frac{10}{\sqrt{n}} \rightarrow n = 125.44 \quad (\text{mínim una } n \text{ de } 126)$$

quin hauria de ser el risc i la confiança sense canviar la n?

$$1.75 = z_{1-\frac{\alpha}{2}} \cdot \frac{10}{\sqrt{100}} \rightarrow 1-\frac{\alpha}{2} = 0.9599 \rightarrow \alpha = 8\% \quad (\text{risc del } 8\%, \text{confiança del } 92\%)$$

Exemple. Diferència temps mitjà en mostres independents

Els temps mitjans d'execució de dos programes provats en diferents bancs de dades independents ($n_1=50$ i $n_2=100$) són: $\bar{y}_1 = 24$ i $\bar{y}_2 = 21$ amb $s_1 = 8$ i $s_2 = 6$. Assumint normalitat i suposant igualtat de variàncies ($\sigma_1^2 = \sigma_2^2$), es desitja estimar si tenen rendiments diferents

Estadístic: $\hat{t} = \frac{(\bar{y}_1 - \bar{y}_2)}{s \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}}$ amb $s^2 = \frac{(n_1-1) \cdot s_1^2 + (n_2-1) \cdot s_2^2}{(n_1-1) + (n_2-1)} = \frac{(50-1) \cdot s_1^2 + (100-1) \cdot s_2^2}{(50-1) + (100-1)} = 45.27$

$$s = 6.72 \quad se = 6.72 \sqrt{\frac{1}{50} + \frac{1}{100}} = 1.16$$

$$IC(\mu_1 - \mu_2, 95\%) = (\bar{y}_1 - \bar{y}_2) \mp t_{n_1+n_2-2, 1-\frac{\alpha}{2}} \cdot s \sqrt{\frac{1}{n_1} + \frac{1}{n_2}} = 3 \mp 1.976 \cdot 1.16 = [0.70, 5.30]$$

El programa "2" triga en mitjana entre 0.7 i 5.3 segons menys amb una confiança del 95%

Si es contrasta una diferència nul·la de les mitjanes poblacionals ($\mu_1 - \mu_2 = 0$ o bé $\mu_1 = \mu_2$), amb confiança 95%: com que el valor 0 no pertany al IC, no és versemblant la igualtat de mitjanes poblacionals d'acord amb l'evidència empírica que les dades aporten.

Funcions en R per a IC. Llista de funcions

- Comprovar la premissa de normalitat:

```
qqnorm(X)
```

```
qqline(X)
```

- z.test per a IC de μ amb σ coneguda (per aquesta funció cal la llibreria BSDA):

```
library(BSDA)
```

```
z.test(X, sigma.x= )      # per a una mostra amb un valor conegut per a la sigma
```

- t.test per a IC de μ (o μ 's) amb σ (o σ 's) desconeguda:

```
t.test(X)                # per a una mostra
```

```
t.test(X-Y) o t.test(X,Y,paired=T) # per a dues mostres aparellades
```

```
t.test(X,Y,var.equal=T) # per a dues mostres independents amb variàncies iguals
```

```
t.test(X,Y,var.equal=F) # per a dues mostres independents amb variàncies diferents
```

- var.test per a IC de σ 's en dues mostres independents:

```
var.test(X,Y)
```

- prop.test i binom.test per a IC de π

BLOC D

Models estadístics. Notació pels casos de models

A. Model sobre un valor concret del paràmetre μ

(predicció)

$$Y = \mu + \varepsilon$$

$$(\hat{Y}_i = \hat{\mu})$$

El model es basa en l'estimació puntual de μ ($\hat{\mu} = \bar{y}$) (i l'interval de confiança (IC))

B. Model comparant el paràmetre μ en mostres aparellades

$$D = \mu_D + \varepsilon \quad \text{amb } D=Y1-Y2 \quad (\text{la diferència com a variable de resposta})$$

$$(\widehat{D}_i = \widehat{\mu}_D)$$

El model es basa en l'estimació puntual de μ_D ($\widehat{\mu}_D = \bar{d}$) (i l'interval de confiança (IC))

C. Model comparant el paràmetre μ en diverses mostres independents ($k \geq 2$ grups)

$$Y = \mu + \vartheta_j + \varepsilon$$

$$(\hat{Y}_i = \hat{\mu} + \hat{\vartheta}_j)$$

El model contempla μ com a mitjana de referència i ϑ_j com a canvi de la mitjana del grup j

i, per tant, té estimacions, puntuals i per IC, per a cada grup

D. Model lineal simple o múltiple

$$Y = \beta_0 + \beta_1 X + \varepsilon$$

$$(\hat{Y}_i = \hat{\beta}_0 + \hat{\beta}_1 X_i)$$

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_k X_k + \varepsilon$$

El model contempla els coeficients β_i (de l'equació d'una recta) amb estimacions puntuals i per IC

+ Altres tècniques (ciència de dades: visualització multidimensional, clustering, machine learning,...)

Per exemple: PCA $[Y1, Y2, \dots Yk]$ ---- transformació geomètrica ----> $[\Psi1, \Psi2 \dots]$ $[\dots \Psi k]$

Exemple. Temps recorre arbres (preordre,inordre,postordre)

```
Temps <- c(392,421,540,475,427,411,476,489,499,454,509,432,539,552,518,511,438,532,447,590,566,557,540,501,575,458,476,485)
metode <- c(1,1,1,1,1,1,1,1,2,2,2,2,2,2,2,2,3,3,3,3,3,3,3,3,3)
nodes <- c(100,140,200,160,120,130,170,180,190,150,160,100,210,200,180,170,140,190,120,190,180,170,160,150,200,110,130,140)
```

Per diverses mides d'arbres (en nombre de nodes) recollim el temps de recórrer-los (o linealitzar-los) usant els tres mètodes indicats. Per explicar la variable de resposta del temps, provem a estimar usant 3 models: model comparant les mitjanes dels tres mètodes, model relacionant amb el nombre de nodes, i model usant mètode i node

```
summary(lm(Temps~nodes+as.factor(metode)))
```

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)	
(Intercept)	239.78109	15.88211	15.098	9.43e-14	***
nodes	1.41868	0.09699	14.628	1.87e-13	***
as.factor(metode)2	22.10498	7.56022	2.924	0.00743	**
as.factor(metode)3	59.82295	7.27785	8.220	1.95e-08	***

Residual standard error: 15.84 on 24 degrees of freedom
 Multiple R-squared: 0.9223, Adjusted R-squared: 0.9125
 F-statistic: 94.91 on 3 and 24 DF, p-value: 1.892e-13

1. Quin és el model estimat?
2. Quins tipus de predicció existeixen?
3. Dóna una predicció puntual d'un temps del mètode 1 amb 200 nodes
4. Quin és el percentatge de variabilitat explicada pel model?
5. Què representa la intercept?
6. Què representa el coeficient de "nodes"?
7. Què representa el coeficient de "as.factor(metode)2"?
8. Com es calcula el t-value?
9. Que representen els p-valors?

Coeficient de determinació

- Per una part fer un rati entre la variabilitat entre les mitjanes dels grups (que correspon a la variabilitat explicada pel model) i la variabilitat global en la resposta Y. Aquest rati l'anomenem **coeficient de determinació** o **R^2** (i l'interpretem com a %):

$$R^2 = \frac{\text{variabilitat explicada}}{\text{variabilitat total}} = \frac{\text{"suma de diferències entre grups, al quadrat"}}{\text{"suma de diferències totals, al quadrat"}} = \frac{SQ_E}{SQ_T}$$


- Com més gran és el valor de R^2 , millor representa el model la relació entre les variables
- Si la relació fos perfectament determinista, la part residual és zero i R^2 màxim, 1 o 100%
- Si X no determina res de la variació de Y, R^2 pren el valor mínim de 0

Model lineal simple i múltiple. Validació


Les premisses del model lineal i els gràfics on comprovar-les són:

(els plots habituals són: plot entre Y i X, qqnorm dels residus, i plots dels residus per ordre de les observacions o per ordre de les prediccions (fitted). Veure en exercicis funcions R per obtenir-los)

➤ **Linealitat** (Y i X s'ajusten a una recta, pel cas simple, o a un pla o hiperplà, pel cas múltiple)




(Plot Y i X on veure si s'ajusta a una recta. En aquest cas, si)



(Gràfic de residus enfront les prediccions on veure si estan per sota i per sobre del 0 uniformement. En aquests gràfics un compleix i l'altre no)

➤ **Homoscedasticitat** ($\varepsilon \sim N(0, \sigma)$) amb variabilitat constant




Gràfic dels residus enfront les prediccions on veure que es distancien del zero de la mateixa forma, sense zones amb més i menys dispersió.

En aquests gràfics un compleix i l'altre no ja que presenta forma d'embut

Atenció: a la referència de la [bibliografia](#) (Estadística per a enginyers informàtics) trobareu més detalls al capítol 7

Model lineal simple i múltiple. Validació

➤ Normalitat ($\varepsilon \sim N(0, \sigma)$ residus amb distribució Normal)




qqnorm (que es pot complementar si cal per un histograma i/o un boxplot) on veure si els residus s'ajusten al model Normal

Si els residus s'ajusten al model Normal implicarà que la variable de resposta també ajusta ja que el que els separa és la part determinista del model

En aquests gràfics un compleix i l'altre no

➤ Independència (mostra aleatòria i no dependència entre observacions)




La independència es garanteix amb un bon disseny i recollida de dades. Però observant els residus enfront l'ordre de recollida es pot veure si hi ha alguna dependència. S'espera no trobar cap patró específic


En aquest cas un compleix i l'altre no, perquè hi ha una tendència creixent dels residus al llarg del temps

Premissa d'efecte additiu constant en model B: Gràfic BA

Es complex



NO Es complex



Models estadístics. Prediccions (i funció en R)

A partir d'una predicció puntual (aplicant la fórmula del model $\hat{Y}_l = f(\hat{\theta})$) es pot calcular un interval a la predicció amb dos tipus d'enfocament:

- **Valor individual**. Estimar el valor de la resposta per a una observació amb uns valors concrets de les variables predictores [Ex: Quin és el retard esperat pel vol BCN-ROM de Vueling de les 8:00?]
`predict(..., interval = "prediction")`
- **Valor esperat**. Estimar la mitjana de la resposta en totes les observacions amb uns valors concrets de les variables predictores [Ex: Quin és el retard promig esperat per als vols BCN-ROM de Vueling que surten a les 8:00?]
`predict(..., interval = "confidence")`

En ambdós casos, **l'estimació puntual de la predicció és la mateixa, però no la seva incertesa**. En el cas del valor puntual tenim un rang més ampli de valors plausibles:

Feu problemes d'e-status i exàmens