

# Probabilitat i Estadística 1

## Problemes Tema 6. Estimació puntual

1. Siguin  $X_1, \dots, X_n$  v.a.i.i.d. amb esperança  $\mu$  i variància  $\sigma^2$ . Es defineix la variància mostral

$$S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2.$$

Proveu que  $\mathbb{E}(S^2) = \sigma^2$ .

*Resolució:*

$$\begin{aligned} \mathbb{E}(S^2) &= \frac{1}{n-1} \mathbb{E} \left( \sum_{i=1}^n (X_i - \bar{X})^2 \right) \\ &= \frac{n}{n-1} \mathbb{E} ((X_1 - \bar{X})^2) \\ &\quad (\mathbb{E}(X_1 - \bar{X}) = 0) \\ &= \frac{n}{n-1} \text{Var}(X_1 - \bar{X}) \\ &= \frac{n}{n-1} (\text{Var}(X_1) + \text{Var}(\bar{X}) - 2\text{Cov}(X_1, \bar{X})) \\ &\quad \left( \text{Cov}(X_1, \bar{X}) = \frac{1}{n} \text{Cov}(X_1, \sum_{j=1}^n X_j) = \frac{1}{n} \text{Cov}(X_1, X_1) = \frac{\sigma^2}{n} \right) \\ &= \frac{n}{n-1} \left( \sigma^2 + \frac{\sigma^2}{n} - 2\frac{\sigma^2}{n} \right) \\ &= \frac{n}{n-1} \frac{(n-1)\sigma^2}{n} \\ &= \sigma^2. \end{aligned}$$

2. Sea  $X_1, \dots, X_n$  una m.a.s. de  $X \sim f(x, \lambda) = \lambda e^{-\lambda x+1}$ ,  $x > 1/\lambda$ . Hallar el estimador de momentos de  $\lambda$ .

*Resultat:*  $\hat{\lambda} = 2/\bar{X}_n$

*Resolució:*

Empezamos calculando el primer momento de  $X$ :

$$\begin{aligned} \mu_1 = \mathbb{E}(X) &= \int_{1/\lambda}^{\infty} x \lambda e^{-\lambda x+1} dx = e \int_{1/\lambda}^{\infty} x \lambda e^{-\lambda x} dx = \\ &\left\{ \begin{array}{l} u = x, du = dx \\ dv = \lambda e^{-\lambda x} dx, v = -e^{-\lambda x} \end{array} \right\} = e \left( -e^{-\lambda x} x \Big|_{1/\lambda}^{\infty} \right) + e \int_{1/\lambda}^{\infty} e^{-\lambda x} dx \\ &= e \cdot e^{-1} \cdot \frac{1}{\lambda} + e \left( -\frac{1}{\lambda} e^{-\lambda x} \Big|_{1/\lambda}^{\infty} \right) = \frac{1}{\lambda} + \frac{1}{\lambda} = \frac{2}{\lambda}. \end{aligned}$$

Ahora despejamos el parámetro en función del primer momento:

$$\mu_1 = \frac{2}{\lambda} \Leftrightarrow \lambda = \frac{2}{\mu_1}.$$

A partir de esa expresión teórica definimos el estimador de momentos del parámetro, reemplazando el momento poblacional  $\mu_1 = \mathbb{E}(X)$  por el muestral  $m_1 = \bar{X}_n$ :

$$\hat{\lambda} = \frac{2}{\bar{X}_n}.$$

3. Siguin  $X_1, \dots, X_n$  variables aleatòries independents idènticament distribuïdes amb funció de densitat

$$f(x; \alpha) = \frac{1 + \alpha x}{2} \mathbb{I}_{[-1,1]}(x), \text{ amb } \alpha \in [-1, 1].$$

- (a) Doneu l'estimador de  $\alpha$  obtingut pel mètode dels moments (al qual anomenarem  $\hat{\alpha}_m$ ).  
 (b) És  $\hat{\alpha}_m$  un estimador no esbiaixat de  $\alpha$ ?  
 (c) Per a  $n = 100$  s'han observat els valors  $x_1, \dots, x_n$  procedents de les variables  $X_1, \dots, X_n$ . D'aquestes dades se sap el següent:

$$\sum_{i=1}^n x_i = -21.44148, \sum_{i=1}^n x_i^2 = 33.56329, \sum_{i=1}^n x_i^3 = -12.76414, \sum_{i=1}^n x_i^4 = 19.74995.$$

Doneu el valor de l'estimador  $\hat{\alpha}_m$  per aquestes dades i calculeu l'error estàndard de l'estimador.

*Resultat:* (a)  $\hat{\alpha}_m = 3\bar{X}_n$ . (b) Sí. (c)  $\hat{\alpha}_m = -0.6432444$ ,  $\text{st.er}(\hat{\alpha}_m) = 0.1622734$

*Resolució:*

(a)

$$\mathbb{E}(X) = \int_{-1}^1 x \frac{1 + \alpha x}{2} dx = \left( \frac{x^2}{4} + \frac{\alpha x^3}{6} \right) \Big|_{-1}^1 = \frac{\alpha}{3}.$$

Per tant,  $\hat{\alpha}_m = 3\bar{X}_n$ .

(b) És no esbiaixat:

$$\mathbb{E}(\hat{\alpha}_m) = 3\mathbb{E}(\bar{X}_n) = 3\mathbb{E}(X) = 3\frac{\alpha}{3} = \alpha.$$

(c) Per aquestes dades

$$\hat{\alpha}_m = 3\bar{x}_n = \frac{3}{n} \sum_{i=1}^n x_i = \frac{3}{100}(-21.44148) = -0.6432444.$$

L'error estàndard de l'estimador és la seva desviació estàndard. Com que

$$\text{Var}(\hat{\alpha}_m) = \text{Var}(3\bar{X}_n),$$

l'error estàndard de  $\hat{\alpha}_m$  és 3 vegades l'error estàndard de  $\bar{X}_n$ , que podem estimar per  $S_x/\sqrt{n}$ , on

$$S_x^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x}_n)^2 = \frac{1}{n-1} \left( \sum_{i=1}^n x_i^2 - n\bar{x}_n^2 \right) = (33.56329 - 100(-.2144148)^2) / 99 = 0.292585$$

Aleshores, l'error estàndard de  $\hat{\alpha}_m$  l'estimarem com

$$\text{st.er}(\hat{\alpha}_m) = 3\sqrt{\frac{0.292585}{100}} = 0.1622734$$

4. Considera una muestra aleatoria simple de la variable  $X \sim U([0, b])$ ,  $b > 0$ . Da las expresiones de los estimadores de momentos i de máxima verosimilitud de  $b$ . Busca sus distribuciones en el muestreo (exactas o asintóticas), calcula su errores estándar, sus sesgos i sus errores cuadráticos medios. ¿Cuál de los dos estimadores de  $b$  es más eficiente?

*Resultat:*  $\text{ECM}_b(\hat{b}_{mom}) = b^2/(12n)$ .  $\text{ECM}_b(\hat{b}_{ML}) = 2b^2/((n+1)(n+2))$ .

*Resolució:*

**Estimador de momentos:**

$$\mu = \mathbb{E}(X) = b/2 \implies \hat{b}_{mom} = 2\bar{X}_n.$$

Distribución en el muestreo:  $\mathbb{E}(\hat{b}_{mom}) = 2(\bar{X}_n) = 2b/2 = b$ .

$\text{Var}(\hat{b}_{mom}) = 4\text{Var}(\bar{X}_n) = 4b^2/(12n) = b^2/(3n)$ , porque  $\sigma^2 = \text{Var}(X) = b^2/12$ .

Además, por el TLC si  $n$  es grande,  $\bar{X}_n \approx N(\mu, \sigma^2/n)$ . Entonces,

$$\hat{b}_{mom} \approx N\left(b, \frac{b^2}{3n}\right).$$

Error estándar:  $\sqrt{\text{Var}(\hat{b}_{mom})} = b/\sqrt{3n}$ .

Sesgo:  $\mathbb{E}(\hat{b}_{mom}) - b = 0$ .

ECM: Como el sesgo es 0, el ECM coincide con la varianza del estimador que vale  $\text{Var}(\hat{b}_{mom}) = b^2/(3n)$ .

**Estimador de máxima verosimilitud:**

$$L(b; x_1, \dots, x_n) = \prod_{i=1}^n \frac{1}{b} I_{[0,b]}(x_i) = \frac{1}{b^n} I_{[x_{(n)}, \infty)}(b)$$

$$\implies \hat{b}_{ML} = X_{(n)} = \max\{X_1, \dots, X_n\}.$$

Distribución en el muestreo: Sabemos que la función de distribución del máximo de  $n$  v.a.i.i.d. es  $F_{X_{(n)}}(x) = F(x)^n$ , donde  $F(x)$  es la función de distribución común a  $X_1, \dots, X_n$ . En el caso de la  $U([0, b])$ ,  $F(x) = x/b$  si  $x \in [0, b]$  (vale 0 si  $x < 0$  y vale 1 si  $x \geq b$ ). Así,  $F_{X_{(n)}}(x) = x^n/b^n$ , y la función de densidad correspondiente es

$$f_{X_{(n)}}(x) = \frac{nx^{n-1}}{b^n} I_{[0,b]}(x),$$

que es también la de  $\hat{b}_{ML}$ .

Calculemos  $\mathbb{E}(X_{(n)})$  y  $\mathbb{E}(X_{(n)}^2)$ :

$$\mathbb{E}(X_{(n)}) = \frac{1}{b^n} \int_0^b nx^n dx = \frac{n}{n+1}b,$$

$$\mathbb{E}(X_{(n)}^2) = \frac{1}{b^n} \int_0^b nx^{n+1} dx = \frac{n}{n+2}b^2.$$

Así,

$$\mathbb{E}(\hat{b}_{ML}) = \frac{n}{n+1}b = \left(1 - \frac{1}{n+1}\right)b = b - \frac{b}{n+1},$$

$$\text{Var}(\hat{b}_{ML}) = \frac{n}{n+2}b^2 - \frac{n^2}{(n+1)^2}b^2 = \frac{n}{(n+2)(n+1)^2}b^2.$$

Error estándar:  $\sqrt{\text{Var}(\hat{b}_{ML})}$ .

Sesgo:  $\text{Sesgo}_b(\hat{b}_{ML}) = \mathbb{E}(\hat{b}_{ML}) - b = -b/(n+1)$ .

ECM:

$$\begin{aligned} \text{ECM}_b(\hat{b}_{ML}) &= \text{Var}(\hat{b}_{ML}) + \text{Sesgo}_b^2(\hat{b}_{ML}) \\ &= \frac{n}{(n+2)(n+1)^2}b^2 + \frac{1}{(n+1)^2}b^2 = \frac{2}{(n+1)(n+2)}b^2. \end{aligned}$$

**Comparación de los dos estimadores:** El ECM del estimador máximo verosímil es menor que el del estimador de momentos si y solo si

$$\frac{2}{(n+1)(n+2)} < \frac{1}{3n} \Leftrightarrow (n+1)(n+2) > 6n$$

$$\Leftrightarrow n^2 + 3n + 2 > 6n \Leftrightarrow n^2 - 3n + (3/2)^2 > 1/4$$

$$\Leftrightarrow (n - (3/2))^2 > 1/4 \Leftrightarrow n - (3/2) > 1/2 \Leftrightarrow n > 2.$$

Además es fácil ver que para  $n = 1$  o para  $n = 2$  los dos estimadores tienen el mismo error cuadrático medio.

En cuanto al comportamiento cuando  $n$  es grande, el ECM del estimador de momentos es  $b^2/(3n)$ , que tiende a 0 a la velocidad de  $1/n$ . Diremos que

$$\text{ECM}_b(\hat{b}_{mom}) = O\left(\frac{1}{n}\right).$$

Por su parte, el ECM del estimador máximo verosímil es  $2b^2/((n+1)(n+2))$ , es decir, tiende a 0 como  $1/n^2$ , es decir,

$$\text{ECM}_b(\hat{b}_{ML}) = O\left(\frac{1}{n^2}\right).$$

Concluimos que, en este caso, el estimador máximo verosímil es asintóticamente más eficiente que el estimador de momentos porque el ECM del primero tiende a 0 mucho más rápido que el del segundo.

En la práctica, el estimador máximo verosímil es mucho más eficiente que el estimador de momentos incluso para tamaños muestrales pequeños.

5. Siguin  $X_1, \dots, X_n$  variables aleatòries independents idènticament distribuïdes amb funció de densitat

$$f(x; \lambda) = \frac{1}{2} \lambda \exp(-\lambda|x|), \quad x \in \mathbb{R} \quad \lambda > 0.$$

Siguin  $x_1, \dots, x_n$  observacions d'aquests variables.

- (a) Doneu l'estimador de  $\lambda$  obtingut pel mètode dels moments.
- (b) Doneu l'estimador de  $\lambda$  obtingut pel mètode de la màxima versemblança.

*Resolució:*

- (a) Per simetria de  $f(x)$  al voltant de 0,

$$\mu_1 = \mathbb{E}(X) = \int_{-\infty}^{\infty} x \frac{1}{2} \lambda e^{-\lambda|x|} dx = 0.$$

Calculem doncs el moment de segon ordre:

$$\mu_2 = \mathbb{E}(X^2) = \int_{-\infty}^{\infty} x^2 \frac{1}{2} \lambda e^{-\lambda|x|} dx = 2 \int_0^{\infty} x^2 \frac{1}{2} \lambda e^{-\lambda x} dx = \int_0^{\infty} y^2 \lambda e^{-\lambda y} dy = \mathbb{E}(Y^2),$$

on  $Y \sim \text{Exp}(\lambda)$ . Com que

$$\mathbb{E}(Y^2) = \text{Var}(Y) + \mathbb{E}(Y)^2 = \frac{1}{\lambda^2} + \frac{1}{\lambda^2} = \frac{2}{\lambda^2},$$

aleshores

$$\mu_2 = \frac{2}{\lambda^2} \Rightarrow \lambda = \left(\frac{2}{\mu_2}\right)^{1/2}.$$

Aleshores, anomenant  $m_2 = (1/n) \sum_{i=1}^n x_i^2$ , l'estimador de  $\lambda$  pel mètode dels moments és

$$\hat{\lambda}_m = \left(\frac{2}{m_2}\right)^{1/2} = \left(\frac{2n}{\sum_{i=1}^n x_i^2}\right)^{1/2}.$$

- (b) La funció de versemblança és

$$L(\lambda; x_1, \dots, x_n) = \prod_{i=1}^n f(x_i; \lambda) = \prod_{i=1}^n \frac{1}{2} \lambda e^{-\lambda|x_i|} = \frac{1}{2^n} \lambda^n e^{-\lambda \sum_{i=1}^n |x_i|}.$$

El seu logaritme és

$$\ell(\lambda; x_1, \dots, x_n) = n \log(2) + n \log(\lambda) - \lambda \sum_{i=1}^n |x_i|.$$

Derivem respecte  $\lambda$ :

$$\ell'(\lambda) = \frac{n}{\lambda} - \sum_{i=1}^n |x_i|, \ell''(\lambda) = -\frac{n}{\lambda^2} < 0.$$

Resolem  $\ell'(\lambda) = 0$ :

$$\frac{n}{\lambda} - \sum_{i=1}^n |x_i| = 0 \Leftrightarrow \lambda = \frac{n}{\sum_{i=1}^n |x_i|}.$$

Com que la segona derivada de  $\ell(\lambda) < 0$  per tot  $\lambda > 0$ , aquest valor que resol  $\ell'(\lambda) = 0$  és el màxim de  $\ell(\lambda)$ . És a dir, l'estimador màxim versemblant de  $\lambda$  és

$$\hat{\lambda}_{MV} = \frac{n}{\sum_{i=1}^n |x_i|}.$$

6. Sea  $X \sim \gamma(\alpha, b)$ ,  $\alpha > 0$ ,  $b > 0$ , con densidad

$$f_X(x|\alpha, b) = \frac{1}{\Gamma(\alpha)b^\alpha} x^{\alpha-1} e^{-x/b}$$

para  $x > 0$ . Se dice que  $Y = X^{-1}$  tiene distribución *gamma invertida* con parámetros  $(\alpha, b)$ , y se denota como  $IG(\alpha, b)$ .

(a) Prueba que la densidad de  $Y$  es

$$f_Y(y; \alpha, b) = \frac{1}{\Gamma(\alpha)b^\alpha} \frac{1}{y^{\alpha+1}} e^{-1/(by)} I_{(0,\infty)}(y).$$

(b) Calcula la esperanza y la varianza de  $Y$ .

*Resolució:*

$$\mathbb{E}(Y) = 1/(b(\alpha - 1)), \text{ Var}(Y) = 1/(b^2(\alpha - 1)^2(\alpha - 2)).$$

*Resolució:*

(a) Se tiene que  $Y = 1/X = g(X)$ , con  $g(x) = 1/x$  una biyección de  $(0, \infty)$  en sí mismo. La función inversa de  $g$  es  $h(y) = 1/y$ . Para calcular la función de densidad de  $Y$  en un  $y \in (0, \infty)$  aplicamos la fórmula del cambio de variable univariante:

$$\begin{aligned} f_Y(y; \alpha, b) &= f_X(h(y); \alpha, b) |h'(y)| \\ &= \frac{1}{\Gamma(\alpha)b^\alpha} \frac{1}{y^{\alpha-1}} e^{-1/(by)} \frac{1}{y^2} = \frac{1}{\Gamma(\alpha)b^\alpha} \frac{1}{y^{\alpha+1}} e^{-1/(by)}. \end{aligned}$$

(b) Calculemos  $\mathbb{E}(Y^r)$  para un  $r < \alpha$  genérico:

$$\begin{aligned} \mathbb{E}(Y^r) &= \mathbb{E}(X^{-r}) = \int_0^\infty \frac{1}{x^r} \frac{1}{\Gamma(\alpha)b^\alpha} x^{\alpha-1} e^{-x/b} \\ &= \frac{\Gamma(\alpha-r)}{\Gamma(\alpha)b^r} \int_0^\infty \frac{1}{\Gamma(\alpha-r)b^{\alpha-r}} x^{(\alpha-r)-1} e^{-x/b} = \frac{\Gamma(\alpha-r)}{\Gamma(\alpha)b^r}. \end{aligned}$$

Así,

$$\begin{aligned} \mathbb{E}(Y) &= \frac{\Gamma(\alpha-1)}{\Gamma(\alpha)b} = \frac{1}{(\alpha-1)b}, \\ \mathbb{E}(Y^2) &= \frac{\Gamma(\alpha-2)}{\Gamma(\alpha)b^2} = \frac{1}{(\alpha-1)(\alpha-2)b^2}, \\ \text{Var}(Y) &= \mathbb{E}(Y^2) - \mathbb{E}(Y)^2 = \frac{1}{(\alpha-1)(\alpha-2)b^2} - \frac{1}{(\alpha-1)^2b^2} \\ &= \frac{(\alpha-1) - (\alpha-2)}{(\alpha-1)^2(\alpha-2)b^2} = \frac{1}{(\alpha-1)^2(\alpha-2)b^2}. \end{aligned}$$

7. Se observa una muestra de una variable aleatoria  $X$  exponencial de parámetro  $\lambda$  (con  $\mathbb{E}(X) = 1/\lambda$ ).

- (a) Prueba que el método de momentos y el de máxima verosimilitud conducen al mismo estimador  $\hat{\lambda}$  del parámetro  $\lambda$ .
- (b) Prueba que la distribución en el muestreo de  $\hat{\lambda}$  es una Gamma invertida e indica cuáles son sus parámetros.
- (c) Calcula el sesgo y el error cuadrático medio de  $\hat{\lambda}$  como estimador de  $\lambda$ .

$$\text{Resultat: } (b) \hat{\lambda} \sim IG(\alpha = n, b = \frac{1}{n\lambda}). \text{ (c) } \text{Sesgo}_{\lambda}(\hat{\lambda}) = \lambda/(n-1), \text{ECM}_{\lambda}(\hat{\lambda}) = \frac{n^2+n-2}{(n-1)^2(n-2)}\lambda^2.$$

*Resolució:*

- (a) Como  $\mu = \mathbb{E}(X) = 1/\lambda$ , el estimador de momentos es  $\hat{\lambda} = 1/\bar{X}_n$ . La función de verosimilitud es

$$L(\lambda; x_1, \dots, x_n) = \lambda^n e^{-\lambda \sum_{i=1}^n x_i},$$

y su logaritmo

$$\ell(\lambda) \equiv \ell(\lambda; x_1, \dots, x_n) = n \log(\lambda) - \lambda \sum_{i=1}^n x_i.$$

Derivando

$$\ell'(\lambda) = \frac{n}{\lambda} - \sum_{i=1}^n x_i,$$

e igualando a 0,  $\ell'(\lambda) = 0$ , se obtiene que el EMV de  $\lambda$  es también  $\hat{\lambda} = 1/\bar{X}_n$  (este valor es el máximo del logaritmo de la verosimilitud porque  $\ell''(\lambda) = -n/\lambda^2 < 0$  para todo  $\lambda$ ).

- (b) Observar que  $X_i \sim \text{Exp}(\lambda) \equiv \text{Gamma}(\alpha = 1, \beta = \lambda)$ . Por tanto  $(1/n)X_i \sim \text{Exp}(n\lambda) \equiv \text{Gamma}(\alpha = 1, \beta = n\lambda)$ . Entonces, aplicando que la suma de Gammas independientes con el mismo parámetro  $\beta$  es también Gamma (con el mismo  $\beta$ , y su parámetro  $\alpha$  es la suma de los  $\alpha$ 's), se tiene que

$$\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i = \sum_{i=1}^n \frac{1}{n} X_i \sim \text{Gamma}(\alpha = n, \beta = n\lambda).$$

Por tanto,  $\hat{\lambda} = 1/\bar{X}_n$  es una Gamma invertida de parámetros  $\alpha = n$  y  $\beta = n\lambda$ . Escribiremos que

$$\hat{\lambda} \sim IG(\alpha = n, \beta = n\lambda)$$

o, usando el parámetro *scale*  $b = 1/\beta$ , que

$$\hat{\lambda} \sim IG\left(\alpha = n, b = \frac{1}{n\lambda}\right).$$

- (c) En uno de los problemas del tema anterior vimos que si  $Y \sim IG(\alpha, b)$  entonces  $\mathbb{E}(Y) = 1/(b(\alpha-1))$ ,  $\text{Var}(Y) = 1/(b^2(\alpha-1)^2(\alpha-2))$ . Entonces

$$\mathbb{E}(\hat{\lambda}) = \frac{1}{\frac{1}{n\lambda}(n-1)} = \frac{n}{n-1}\lambda = \left(1 + \frac{1}{n-1}\right)\lambda,$$

luego el sesgo de  $\hat{\lambda}$  como estimador de  $\lambda$  es  $\text{Sesgo}_{\lambda}(\hat{\lambda}) = \lambda/(n-1)$ . Y su varianza es

$$\text{Var}(\hat{\lambda}) = \frac{1}{\frac{1}{n^2\lambda^2}(n-1)^2(n-2)} = \frac{n^2}{(n-1)^2(n-2)}\lambda^2.$$

Por tanto, el error cuadrático medio de  $\hat{\lambda}$  como estimador de  $\lambda$  será

$$\begin{aligned} \text{ECM}_{\lambda}(\hat{\lambda}) &= \text{Var}(\hat{\lambda}) + \text{Sesgo}_{\lambda}^2(\hat{\lambda}) \\ &= \frac{n^2}{(n-1)^2(n-2)}\lambda^2 + \frac{1}{(n-1)^2}\lambda^2 = \frac{n^2+n-2}{(n-1)^2(n-2)}\lambda^2. \end{aligned}$$

8. Sean  $X_1, \dots, X_n$  v.a. independientes tales que  $X_i \sim \text{Poisson}(i\theta)$ ,  $\theta > 0$ . Encuentra el estimador máximo verosímil de  $\theta$ , prueba que es insesgado y calcula su varianza.

$$\text{Resultat: } \hat{\theta} = \frac{1}{a_n} \sum_{i=1}^n X_i \text{ con } a_n = \sum_{i=1}^n i = \frac{n(n+1)}{2}, \text{ Var}(\hat{\theta}) = \theta/a_n.$$

*Resolución:*

Recordemos que la función de probabilidad de la Poisson de parámetro  $\lambda$  es

$$\Pr(X = x; \lambda) = e^{-\lambda} \frac{\lambda^x}{x!}.$$

Así la función de verosimilitud es

$$L(\theta; x_1, \dots, x_n) = \prod_{i=1}^n \Pr(X_i = x_i; i\theta) = \prod_{i=1}^n e^{-i\theta} \frac{(i\theta)^{x_i}}{x_i!}$$

y su logaritmo

$$\ell(\theta) \equiv \ell(\theta; x_1, \dots, x_n) = -\theta \sum_{i=1}^n i + \log(\theta) \sum_{i=1}^n x_i + \sum_{i=1}^n x_i \log(i) - \sum_{i=1}^n \log(x_i!).$$

Entonces, llamando  $a_n = \sum_{i=1}^n i = n(n+1)/2$ ,

$$\ell'(\theta) = -a_n + \frac{\sum_{i=1}^n x_i}{\theta}.$$

Resolviendo la ecuación  $\ell'(\theta) = 0$ , obtenemos

$$\hat{\theta} = \frac{1}{a_n} \sum_{i=1}^n x_i.$$

Para confirmar que es un máximo calculamos la segunda derivada y vemos que es negativa para todo  $\theta$ :

$$\ell''(\theta) = -\frac{\sum_{i=1}^n x_i}{\theta^2} < 0.$$

La esperanza de  $\hat{\theta}$  es

$$\mathbb{E}(\hat{\theta}) = \frac{1}{a_n} \sum_{i=1}^n \mathbb{E}(X_i) = \frac{1}{a_n} \sum_{i=1}^n i\theta = \frac{\theta}{a_n} \sum_{i=1}^n i = \theta.$$

Su varianza es

$$\text{Var}(\hat{\theta}) = \frac{1}{a_n^2} \sum_{i=1}^n \text{Var}(X_i) = \frac{1}{a_n^2} \sum_{i=1}^n i\theta = \frac{\theta}{a_n^2} \sum_{i=1}^n i = \frac{\theta}{a_n}.$$

También podemos determinar la distribución en el muestreo de  $\hat{\theta} = (\sum_{i=1}^n X_i) / a_n$ . Dado que la suma de v.a. de Poisson independientes es también Poisson (con parámetro igual a la suma de los parámetros de las variables sumadas) se tiene que

$$\hat{\theta} = \frac{\sum_{i=1}^n X_i}{a_n} \sim \frac{1}{a_n} \text{Poisson}\left(\sum_{i=1}^n i\theta\right) \equiv \frac{1}{a_n} \text{Poisson}(a_n\theta).$$

De ahí podríamos haber obtenido también el valor de la esperanza y la varianza de  $\hat{\theta}$ .

9. Sean  $X_1, \dots, X_n$  v.a. independientes tales que  $X_i \sim N(i\theta, 1)$ ,  $\theta \in \mathbb{R}$ . Encuentra el estimador máximo verosímil de  $\theta$ , prueba que es insesgado y calcula su varianza.

*Resolución:*

$$\hat{\theta} = \frac{1}{b_n} \sum_{i=1}^n iX_i \text{ con } b_n = \sum_{i=1}^n i^2 = \frac{n(n+1)(2n+1)}{6}, \text{ Var}(\hat{\theta}) = 1/b_n.$$

*Resolució:*

La función de densidad de  $X_i$  es

$$f_{X_i}(x_i) = \frac{1}{\sqrt{2\pi}} e^{-\frac{1}{2}(x_i - i\theta)^2}$$

y su logaritmo

$$\log f_{X_i}(x_i) = -\frac{1}{2} \log(2\pi) - \frac{1}{2}(x_i - i\theta)^2 = -\frac{\log(2\pi)}{2} - \frac{1}{2}(x_i^2 - 2ix_i\theta + i^2\theta^2).$$

Así, el logaritmo de la función de verosimilitud es

$$\begin{aligned}\ell(\theta) &\equiv \ell(\theta; x_1, \dots, x_n) = \sum_{i=1}^n \log f_{X_i}(x_i) \\ &= -\frac{n \log(2\pi)}{2} - \frac{1}{2} \sum_{i=1}^n (x_i^2 - 2ix_i\theta + i^2\theta^2).\end{aligned}$$

Entonces,

$$\ell'(\theta) = -\frac{1}{2} \sum_{i=1}^n (-2ix_i + 2i^2\theta) = \sum_{i=1}^n ix_i - \theta \sum_{i=1}^n i^2.$$

Resolviendo la ecuación  $\ell'(\theta) = 0$ , obtenemos

$$\hat{\theta} = \frac{1}{b_n} \sum_{i=1}^n ix_i,$$

donde  $b_n = \sum_{i=1}^n i^2 = n(n+1)(2n+1)/6$ . Para confirmar que es un máximo calculamos la segunda derivada y vemos que es negativa para todo  $\theta$ :

$$\ell''(\theta) = -b_n < 0.$$

La esperanza de  $\hat{\theta}$  es

$$\mathbb{E}(\hat{\theta}) = \frac{1}{b_n} \sum_{i=1}^n i \mathbb{E}(X_i) = \frac{1}{b_n} \sum_{i=1}^n i^2 \theta = \frac{\theta}{b_n} \sum_{i=1}^n i^2 = \theta.$$

Su varianza es

$$\text{Var}(\hat{\theta}) = \frac{1}{b_n^2} \sum_{i=1}^n i \text{Var}(X_i) = \frac{1}{b_n^2} \sum_{i=1}^n i^2 = \frac{1}{b_n}.$$

10. Sean  $X_1, \dots, X_n$  v.a. independientes tales que  $X_i \sim \text{Exp}(1/(i\theta))$ ,  $E(X_i) = i\theta$ ,  $\theta > 0$ . Encuentra el estimador máximo verosímil de  $\theta$ , prueba que es insesgado y calcula su varianza.

$$\text{Resultat: } \hat{\theta} = \frac{1}{n} \sum_{i=1}^n \frac{X_i}{i}, \text{ Var}(\hat{\theta}) = \theta^2/n.$$

*Resolució:*

La función de densidad de  $X_i$  es

$$f_{X_i}(x_i) = \frac{1}{i\theta} e^{-\frac{x_i}{i\theta}}$$

y su logaritmo

$$\log f_{X_i}(x_i) = -\log(i) - \log(\theta) - \frac{x_i}{i\theta}.$$

Así, el logaritmo de la función de verosimilitud es

$$\ell(\theta) \equiv \ell(\theta; x_1, \dots, x_n) = \sum_{i=1}^n \log f_{X_i}(x_i)$$



$$= -\sum_{i=1}^n \log(i) - n \log(\theta) - \frac{1}{\theta} \sum_{i=1}^n \frac{x_i}{i}.$$

Entonces,

$$\ell'(\theta) = -\frac{n}{\theta} + \frac{1}{\theta^2} \sum_{i=1}^n \frac{x_i}{i}.$$

Resolviendo la ecuación  $\ell'(\theta) = 0$ , obtenemos

$$\hat{\theta} = \frac{1}{n} \sum_{i=1}^n \frac{x_i}{i}.$$

Para confirmar que es un máximo calculamos la segunda derivada y vemos que es negativa para todo  $\theta = \hat{\theta}$ :

$$\ell''(\theta) = \frac{n}{\theta^2} - \frac{2}{\theta^3} \sum_{i=1}^n \frac{x_i}{i}$$

y, por tanto,

$$\ell''(\hat{\theta}) = \frac{n}{\hat{\theta}^2} - \frac{2}{\hat{\theta}^3} n \hat{\theta} = -\frac{n}{\hat{\theta}^2} < 0.$$

La esperanza de  $\hat{\theta}$  es

$$\mathbb{E}(\hat{\theta}) = \frac{1}{n} \sum_{i=1}^n \frac{\mathbb{E}(X_i)}{i} = \frac{1}{n} \sum_{i=1}^n \frac{i\theta}{i} = \frac{\theta}{n} \sum_{i=1}^n 1 = \theta.$$

Su varianza es

$$\text{Var}(\hat{\theta}) = \frac{1}{n^2} \sum_{i=1}^n \frac{\text{Var}(X_i)}{i^2} = \frac{1}{n^2} \sum_{i=1}^n \frac{i^2 \theta^2}{i^2} = \frac{\theta^2}{n^2} \sum_{i=1}^n 1 = \frac{\theta^2}{n}.$$

11. **Hardy-Weinberg law.** (Problem 6.2.19 of Evans and Rosenthal, 2010).

The Hardy-Weinberg law in genetics says that the proportions of genotypes  $AA$ ,  $Aa$ , and  $aa$  are  $\theta^2$ ,  $2\theta(1-\theta)$ , and  $(1-\theta)^2$ , respectively, where  $\theta \in [0, 1]$ . Suppose that in a sample of  $n$  individuals from the population (small relative to the size of the population), we observe  $x_1$  individuals of type  $AA$ ,  $x_2$  individuals of type  $Aa$ , and  $x_3$  individuals of type  $aa$ .

- What distribution do the counts  $(X_1, X_2, X_3)$  follow?
- Record the likelihood function, the log-likelihood function, and the score function for  $\theta$ .
- Record the form of the MLE for  $\theta$ .

*Resultat:*

*Resolució:*

12. Consideramos una muestra de  $X$  exponencial de parámetro  $\lambda$  (con  $\mathbb{E}(X) = 1/\lambda$ ), como en el problema 7. Da la distribución asintótica de  $\hat{\lambda}$  (el estimador de momentos y también el máximo verosímil de  $\lambda$ ) usando la teoría asintótica del estimador máximo verosímil.

*Resultat:*

*Resolució:*

El estimador es  $\hat{\lambda} = 1/\bar{X}_n$ . La teoría asintótica del estimador máximo verosímil nos dice que

$$\sqrt{n} \left( \hat{\lambda}_n - \lambda \right) \xrightarrow{n \rightarrow \infty} N \left( 0, \frac{1}{I(\lambda)} \right) \text{ en distribución,}$$

donde  $I(\lambda)$  es la Información de Fisher que sobre  $\lambda$  contiene el modelo (o la que contiene una observación de  $X$ ):

$$I(\lambda) = \text{Var}_{\lambda} \left( \frac{\partial \log(f(X; \lambda))}{\partial \lambda} \right) = -\mathbb{E}_{\lambda} \left( \frac{\partial^2 \log(f(X; \lambda))}{\partial \lambda^2} \right).$$

Calculemos esas cantidades:

$$\begin{aligned} f(x; \lambda) &= \lambda e^{-\lambda x} \Rightarrow \log(f(x; \lambda)) = \log(\lambda) - \lambda x \\ \Rightarrow \frac{\partial \log(f(x; \lambda))}{\partial \lambda} &= \frac{1}{\lambda} - x \Rightarrow \frac{\partial^2 \log(f(x; \lambda))}{\partial \lambda^2} = -\frac{1}{\lambda^2}. \end{aligned}$$

Observar que las dos formas alternativas de calcular la Información de Fisher dan lugar al mismo resultado:

$$\begin{aligned} \text{Var}_\lambda \left( \frac{\partial \log(f(X; \lambda))}{\partial \lambda} \right) &= \text{Var}_\lambda \left( \frac{1}{\lambda} - X \right) = \text{Var}_\lambda(X) = \frac{1}{\lambda^2}, \\ -\mathbb{E}_\lambda \left( \frac{\partial^2 \log(f(X; \lambda))}{\partial \lambda^2} \right) &= -\mathbb{E}_\lambda \left( -\frac{1}{\lambda^2} \right) = \frac{1}{\lambda^2}. \end{aligned}$$

Así,  $I(\lambda) = 1/\lambda^2$  y, por tanto,

$$\sqrt{n}(\hat{\lambda}_n - \lambda) \xrightarrow{n \rightarrow \infty} N\left(0, \frac{1}{I(\lambda)} = \lambda^2\right) \text{ en distribución.}$$

13. Sigui  $X \sim \text{Bin}(n, p)$ . Es defineix el *log-odds* com  $\psi = \log(p/(1-p))$ . Doneu l'estimador màxim versemblant de  $\psi$  i indiqueu quina és la seva distribució asimptòtica fent servir la Informació de Fisher.

*Resultat:*

*Resolució:*

Observar que  $\psi = \tau(p) = \log(p/(1-p))$  y que  $\tau(p)$  es una función biyectiva. Entonces, por el principio de invarianza, el estimador máximo verosímil de  $\psi$  es

$$\hat{\psi}_n = \tau(\hat{p}_n) = \log\left(\frac{\hat{p}_n}{1-\hat{p}_n}\right)$$

donde  $\hat{p}_n = X/n$  es la proporción muestral de éxitos en los primeros  $n$  experimentos, que sabemos que es el estimador máximo verosímil de  $p$ . (Usamos el subíndice  $n$  porque vamos a hablar del comportamiento asintótico del estimador).

La teoría asintótica del estimador máximo verosímil nos dice que

$$\sqrt{n}(\hat{\psi}_n - \psi) = \sqrt{n}(\tau(\hat{p}_n) - \tau(p)) \xrightarrow{n \rightarrow \infty} N\left(0, \frac{(\tau'(p))^2}{I(p)}\right)$$

en distribución, donde  $I(p)$  es la Información de Fisher que sobre  $p$  contiene el modelo (o la que contiene una v.a.  $Y$  Bernouilli de parámetro  $p$ ):

$$\begin{aligned} I(p) &= \text{Var}_p \left( \frac{\partial}{\partial p} \log(p^Y (1-p)^{(1-Y)}) \right) \\ &= \text{Var}_p \left( \frac{\partial}{\partial p} \{Y \log(p) + (1-Y) \log(1-p)\} \right) \\ &= \text{Var}_p \left( \frac{Y}{p} - \frac{1-Y}{1-p} \right) = \text{Var}_p \left( \frac{Y-1}{p(1-p)} \right) \\ &= \frac{p(1-p)}{p^2(1-p)^2} = \frac{1}{p(1-p)}. \end{aligned}$$

También podríamos haber calculado  $I(p)$  así:

$$\begin{aligned} I(p) &= -\mathbb{E}_p \left( \frac{\partial^2}{\partial p^2} \log(p^Y (1-p)^{(1-Y)}) \right) \\ &= -\mathbb{E}_p \left( \frac{\partial}{\partial p} \left\{ \frac{Y}{p} - \frac{1-Y}{1-p} \right\} \right) = -\mathbb{E}_p \left( -\frac{Y}{p^2} - \frac{1-Y}{(1-p)^2} \right) \end{aligned}$$

$$= \frac{1}{p} + \frac{1}{1-p} = \frac{1}{p(1-p)}.$$

Calculemos ahora  $\tau'(p)$ :

$$\tau'(p) = \frac{d}{dp} \log \left( \frac{p}{1-p} \right) = \frac{1-p}{p} \frac{(1-p) - p(-1)}{(1-p)^2} = \frac{1}{p(1-p)}.$$

Así concluimos que

$$\sqrt{n} \left( \hat{\psi}_n - \psi \right) \xrightarrow{n \rightarrow \infty} N \left( 0, \frac{\frac{1}{p^2(1-p)^2}}{\frac{1}{p(1-p)}} = \frac{1}{p(1-p)} \right).$$